

# Estudo de Caso 2 - Avaliação e comparação do retorno médio de ações

Ana Júlia Martins, Antônio Carlos da Anunciação, Melchior Augusto Syrio de Melo

25 de novembro de 2024

```
##
## Attaching package: 'dplyr'

## The following objects are masked from 'package:stats':
##
##   filter, lag

## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union

##
## Attaching package: 'MASS'

## The following object is masked from 'package:dplyr':
##
##   select

##
## Attaching package: 'TH.data'

## The following object is masked from 'package:MASS':
##
##   geyser
```

## Resumo

Este estudo de caso realiza a análise de um conjunto de 5 ações sobre um período de 36 meses para avaliar por meio das taxas de retorno e do teste ANOVA a melhor ação para obter a melhor rentabilidade no próximo mês.

## 1. Design do Experimento

Para realizar a análise estatística, estabelecemos as seguintes hipóteses:

- **Hipótese Nula ( $H_0$ ):** Não existe diferença no valor médio dos retornos das ações, isto é, não existe diferença no tamanho dos efeitos  $\tau_i$ .

$$\left\{ H_0 : \tau_i = 0, \forall i \in \{1, 2, \dots, a\} \right.$$

- **Hipótese Alternativa ( $H_a$ ):** Existe ao menos uma ação com um efeito significativamente diferente de zero, ou seja, com um retorno médio mensal superior às demais.

$$\left\{ H_1 : \exists \tau_i \neq 0 \right.$$

Para testar a hipótese definida, será utilizado o teste ANOVA. Se decidirmos pela rejeição da hipótese nula e as premissas do teste ANOVA forem validadas, precisaremos determinar quais ações possuem retorno significativamente maior do que as demais. Para isso, vamos realizar comparações múltiplas para identificar quais pares de ação diferem significativamente, utilizando o método de Tukey.

## 2. Descrição do conjunto de dados

Os dados utilizados neste estudo são referentes aos preços de fechamento de cinco ações, extraídos de um arquivo CSV. Cada arquivo contém 36 linhas e 5 colunas, onde:

- Cada linha representa o preço de fechamento mensal das ações, com a linha 1 correspondendo ao mês mais recente e a linha 36 ao mês mais distante.
- Cada coluna representa uma das cinco ações analisadas.
- O conteúdo da posição (i, j) refere-se ao preço de fechamento da ação j no mês i.

Com base nesse conjunto de dados, foi calculado o retorno mensal de cada ação utilizando a fórmula:

$$\text{Retorno} = \frac{\text{Preço no mês atual} - \text{Preço no mês anterior}}{\text{Preço no mês anterior}}$$

Posto que o retorno do investimento depende do preço anterior, o primeiro mês da série temporal não terá um valor para o retorno do investimento. Isto é, o 36º mês da série, por não haver informação anterior a ele, não terá valor definido. Logo, o resultado é uma tabela com 35 retornos mensais para cada uma das cinco ações.

```
# Ler o arquivo CSV com os preços de fechamento das ações
precos <- read.csv("DadosAcoesGrupoH.csv", header=FALSE)
colnames(precos) <- paste0("Acao_", 1:5)

# Calcular o retorno mensal de cada ação
# Retorno mensal = (Preço atual - Preço anterior) / Preço anterior
retornos <- precos
for (j in 1:ncol(precos)) {
  for (i in 2:(nrow(precos))) {
    retornos[i-1, j] <- ((precos[i-1, j] - precos[i, j])) / precos[i, j]
  }
}

# Remover a ultima linha, porque a primeira linha da tabela de preços foi descartada
retornos <- retornos[-36, ]

#retornos<-retornos[nrow(retornos):1,]
```

### 3. Análise Exploratória

Antes de realizar os testes de hipótese, foi realizada uma análise exploratória para obter uma visão geral dos dados. A Figura @ref{fig:boxplot} fornece um boxplot para comparar as distribuições dos retornos das ações.

```
# Transforma os dados para visualização
retornos_melt <- melt(retornos, variable.name = "Acoes", value.name = "Retorno")

# Boxplot dos retornos
ggplot(retornos_melt,
       aes(x = Acoes, y = Retorno, fill = Acoes)) +
  geom_boxplot() +
  geom_point(alpha = 0.5) +
  ggtitle("Retorno das Ações",
         "(dados originais + boxplots)") +
  theme(legend.position = "none")
```




Figure 1: Retorno das Ações (dados originais + boxplots)

A análise gráfica indica que a Ação 2 aparenta apresentar o maior retorno médio entre as ações analisadas.

### 4. Análise Estatística

Para validar nossas observações iniciais, realizamos um teste ANOVA para avaliar as diferenças nos retornos das ações.

```
retornos_melt$Acoes <- as.factor(retornos_melt$Acoes)
modelo <- aov(Retorno ~ Acoes, data = retornos_melt)
summary(model)
```

```
##           Df Sum Sq Mean Sq F value Pr(>F)
## Acoes      4 0.01434 0.003586   34.45 <2e-16 ***
## Residuals 170 0.01769 0.000104
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Como resultado do teste, obteve-se uma estatística  $F = 34,45$  e um p-valor  $< 2e-16$ .

Diante do resultado do teste ANOVA, podemos rejeitar, com nível de significância  $\alpha = 0,05$ , a hipótese nula de que as médias de retorno das cinco ações são iguais.

Esse resultado indica que nem todas as ações têm retornos médios semelhantes e, para identificar quais ações possuem maior retorno médio, realizamos um teste de Tukey, da forma de todos contra todos. Com 5 graus de liberdade - número de ações em análise, o teste de Tukey da forma todos contra todos proverá 10 análises comparativas entre as ações. Seus resultados são mostrados na Figura @ref{fig:turkey}.

```
# Comparações múltiplas
library(multcomp)

mc1 <- glht(model,
             linfct = mcp(Acoes = "Tukey"))
#summary(mc1)
mc1_CI <- confint(mc1, level = 0.95)

par(mar = c(5, 10, 4, 2)) # margens
plot(mc1_CI,
     xlab = "Retornos",
     cex.axis = 1.2,
     cex = 2,
     main = "Comparações Múltiplas - Tukey")
```

As comparações mais significativas são entre a Ação 2 e as Ações 1, 3, 4 e 5, todas com p-valor  $< 0,001$ , indicando que essas ações têm médias de retorno significativamente diferentes. As Ações 1, 3, 4 e 5, por sua vez, apresentam pelo menos uma diferença não significativa quando comparadas entre si.

Confirmando a suspeita inicial, o teste de Tukey indica que a Ação 2 tem o maior retorno médio entre as ações analisadas, visto que as comparações entre a Ação 2 e as outras ações todas mostram diferenças significativas.

## 5. Verificação das Premissas do Modelo

Para validar a rejeição de  $H_0$ , precisamos validar as premissas do teste do ANOVA. Presume-se a independência entre as séries temporais, a igualdade da variância entre os grupos (homoscedasticidade) e a normalidade de distribuição dos resíduos do teste.

A variação das ações em uma bolsa de valores depende de fatores internos às empresas mas também de fatores externos. Esses fatores podem afetar ou não o conjunto das ações. A aleatoriedade o entendimento de que são empresas diferentes, controlados por grupos econômicos diferentes endossa a premissa de independência entre o comportamento das ações.

Podemos analisar estatisticamente a independência dos parâmetros do modelo por meio do teste de Durbin-Watson.

```
library(car)
```




Figure 2: Comparações múltiplas - Turkey

```
## Loading required package: carData

##
## Attaching package: 'car'

## The following object is masked from 'package:dplyr':
##
##      recode

durbinWatsonTest(model)
```

```
## lag Autocorrelation D-W Statistic p-value
## 1 -0.139798 2.275458 0.116
## Alternative hypothesis: rho != 0
```

O resultado do teste nos dá uma Estatística Durbin-Watson de 2,28, muito próxima de 2 com um p-valor de 13,8%. Por definição, a proximidade da estatística DW próximo a 2 nos indica a independência dos valores. Conforme a saída do teste, não podemos rejeitar a hipótese nula. Isto é: não há autocorrelação de primeira ordem no modelo: as observações são independentes.

O segundo passo foi analisar a normalidade dos resíduos. Para tal, foi utilizado o teste de Shapiro-Wilk e análise gráfica dos resíduos.

```
par(mfrow=c(2,2), mai=.3*c(1,1,1,1))
plot(model,pch=16,lty=1,lwd=2)
```

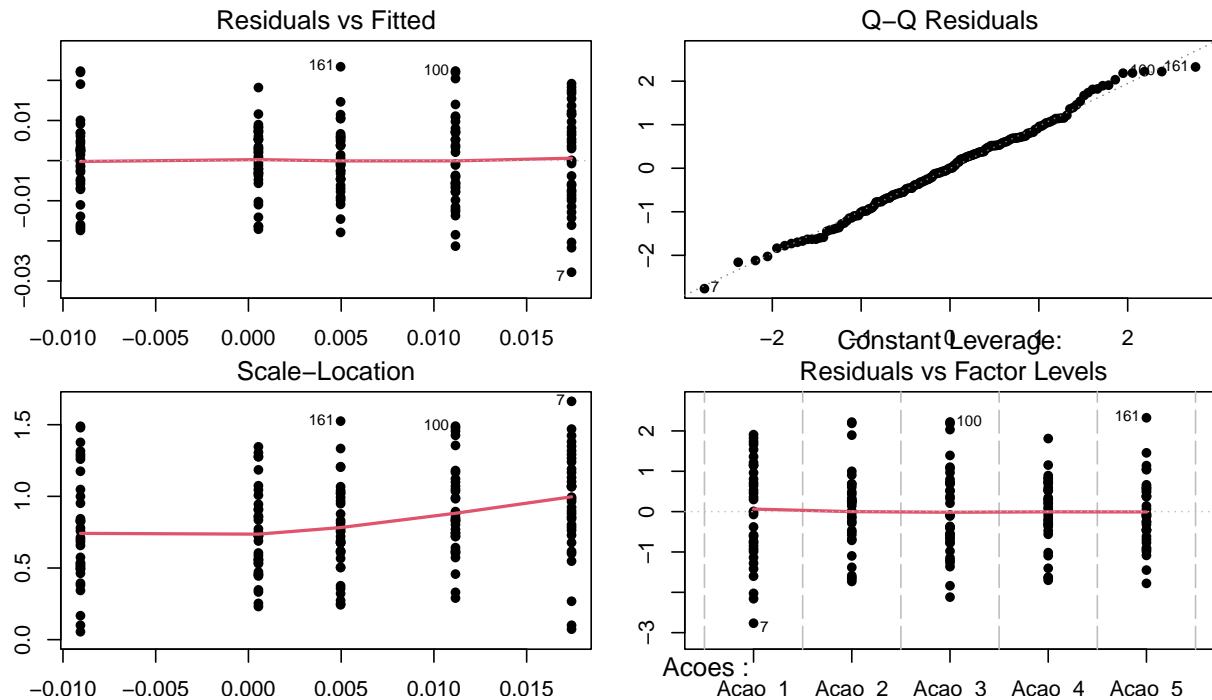


Figure 3: Residual plots for the anova model

```
shapiro.test(model$residuals)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  model$residuals
## W = 0.99337, p-value = 0.6136
```

```
library(car)
qqPlot(model$residuals,
  pch = 16,
  lwd = 3,
  cex = 2,
  las = 1,
  main = "Análise Gráfica da Normalidade dos Resíduos do modelo ANOVA")
```

```
## [1] 7 161
```

O teste de Shapiro-Wilk nos fornece um resultado da estatística  $W = 0.99337$  e p-valor de 61,36%. Isso nos indica que os resíduos encaixam muito bem sobre uma distribuição normal com p-valor superior a 5%. Pela análise gráfica, podemos observar que os resíduos de fato tem um comportamento bem ajustado em torno de uma distribuição normal, até mesmo as amostras mais distantes de seu centro. Logo, por meio destas análises podemos validar a premissa da normalidade dos resíduos do modelo.

Para validar a premissa da homoscedasticidade foi realizado o teste de Fligner-Killen.

### Gráfica da Normalidade dos Resíduos do modelo




Figure 4: Residual plots for the anova model

```
fligner.test(Retorno ~ Acoes, data = retornos_melt)
```

*# aqui nao acusa homoscedasticidade, logo temos que justificar que  
#ANOVA é relativamente robusto a violações modestas da homoscedas- ticidade desde que as observações se*


```
##  
## Fligner-Killeen test of homogeneity of variances  
##  
## data: Retorno by Acoes  
## Fligner-Killeen:med chi-squared = 11.502, df = 4, p-value = 0.02146
```

O resultado deste teste nos informa que com um p-valor de 2,14% devemos rejeitar a hipótese nula de que as variâncias em cada um dos grupos é a mesma. Logo este teste não nos confirma a igualdade da variância entre os grupos.

Aprofundando a análise, o p-valor de 2,14% para o Fligner-Killeen nos pode indicar uma violação não acentuada da igualdade das variâncias.

Seguindo para uma análise do gráfico dos resíduos pelos valores ajustados podemos observar que o comportamento de cada um dos grupos demonstra um comportamento similar para as amostras. Caso escolhamos uma amostra aleatória de qualquer um dos grupos, não podemos afirmar com certeza de qual dos grupos essa amostra pertence.

```
plot(x = model$fitted.values, y = model$residuals, xlab = c("Ações"), ylab="Valores",xaxt='n')
```



Logo, apesar do teste de Fligner-Killeen não acusar homoscedasticidade, podemos afirmar que essa violação é moderada posto que as observações dos grupos são balanceadas. Sabendo que o teste ANOVA é robusto a tais violações moderadas da variância entre os grupos, podemos manter a validação da premissa da homoscedasticidade, validando nossa análise.

```
alpha<-0.05
beta<-0.05
vartau <- var(retornos_melt[,2])
n<-35
sigma<-sd(retornos_melt[,2])
```

```
power.anova.test(
  groups = 5,
  between.var = vartau,
  within.var = sigma^2,
  sig.level = alpha,
  power = 1 - beta)
```

```
##
##      Balanced one-way analysis of variance power calculation
##
##      groups = 5
##      n = 5.692662
##      between.var = 0.000184101
##      within.var = 0.000184101
##      sig.level = 0.05
```



```
##           power = 0.95
##
## NOTE: n is number in each group
```

## **6. Conclusões e Recomendações**

The discussion of your results, and the scientific/technical meaning of the effects detected, should be placed here. Always be sure to tie your results back to the original question of interest!

## **7. Atividades Específicas**

- Ana Julia: Design do experimento, análise estatística, análise exploratória e descrição do conjunto de dados (redação e código)
- Antônio: Análise do Experimento, análise estatística e validação das premissas.
- Melchior: Validação das premissas do teste, revisão do relatório e dados.